

Motor de Búsqueda con TF-IDF

Aplicado al reglamento académico de Fundación Universitaria Konrad Lorenz

Por:
Jose Carlos Bermudez Galván
Daniela Alejandra Benavidez Rincon

¿Por qué TF-IDF en lugar de búsqueda simple?

Búsqueda Simple

- Trata todas las palabras por igual
- No diferencia términos comunes vs únicos
- Resultados sin orden de relevancia
- Falsos positivos por palabras frecuentes

TF-IDF

- Pondera términos por frecuencia y rareza
- Penaliza palabras comunes como 'la', 'de'
- Rankea documentos por relevancia real
- Robusto para colecciones pequeñas y grandes

Tabla de IDF: Palabras más relevantes vs. más comunes

IDF más bajo (palabras comunes)

Palabra	IDF
a	-0.0953
o	-0.0953
en	0.0000
la	0.0000
es	0.1054

IDF más alto (palabras únicas)

Palabra	IDF
veinte	1.6094
tecnologico	1.6094
registra	1.6094
minima	1.6094
debe	1.6094

¿Qué indica un IDF alto?

Alta especificidad: Aparecen en muy pocos documentos del corpus.

Mayor poder discriminativo: Permiten distinguir un artículo de los demás.

Términos técnicos del reglamento: Ej: 'obligatoria', 'calidad', 'periodo' son conceptos únicos.

Más útiles para el ranking: Elevan el score solo del documento que los contiene.

Casos de Prueba — Top 3 Documentos Recuperados

"matricula estudiante"

1. Doc 4 (0.1212): la matricula se cancela por decision voluntaria del estudiante...
2. Doc 2 (0.0947): la matricula es el acto mediante el cual la institucion reconoce...
3. Doc 3 (0.0482): la matricula debe renovarse dentro de los plazos fijados...

"inasistencia asignatura reprobada"

1. Doc 7 (0.2742): cuando la inasistencia iguale o supere el porcentaje... reprobada
2. Doc 6 (0.0547): el numero maximo de ausencias permitido en una asignatura...
3. Doc 1 (0.0000): la institucion podra ofrecer programas academicos en niveles...

"evaluacion calificacion aprobatoria"

1. Doc 10 (0.1694): la calificacion aprobatoria minima para programas de pregrado...
2. Doc 9 (0.0894): la evaluacion academica comprende actividades y procedimientos...
3. Doc 1 (0.0000): la institucion podra ofrecer programas academicos en niveles...

Tabla Comparativa de Scores TF-IDF

Consulta	Doc #	Documento	Score
matricula estudiante	3	la matricula reconoce formalmente...	0.1788
matricula estudiante	5	la matricula puede cancelarse...	0.1788
matricula estudiante	4	la matricula debe renovarse...	0.1309
inasistencia asignatura	7	la inasistencia mayor al 20 por ciento...	0.2682
inasistencia asignatura	1	los programas academicos pueden ser...	0.0000
inasistencia asignatura	2	la institucion puede ofrecer...	0.0000
evaluacion academica	9	la evaluacion academica mide...	0.4024
evaluacion academica	1	los programas academicos pueden ser...	0.0000
evaluacion academica	2	la institucion puede ofrecer...	0.0000

Limitaciones del Sistema



Sin semántica: No entiende sinónimos ni frases. 'matrícula' y 'inscripción' son palabras distintas.



Sensible al preprocesamiento: Sin normalización, 'academico' y 'académico' no coinciden.



Corpus pequeño: Con solo 10 documentos, el IDF es poco estable y sensible.



Sin contexto: Dos documentos con igual score no se pueden diferenciar sin criterio adicional.

Integración con un Flujo RAG + LLM



¡Gracias!

Motor de Búsqueda con TF-IDF · Reglamento Académico